

Группы потребления

Егор Щеренко

Я делю муниципалитеты на группы по структуре расходов и слежу, кто и когда переходит в другую группу за два года.

2 016

муниципальных образований

24


помесечных графа,
2023–2024

7

устойчивых групп во времени

3

уровня в годовом каркасе



- Сбалансированные районы
- Продуктовые районы с маркетплейсами
- Продуктовые районы вне лета
- Города и Москва
- Ставрополье и Северный Кавказ
- Восток и Север
- Малые районы Якутии
- прочие короткие группы

Цвет показывает группу, в которой МО провело больше всего из 24 месяцев. 10 МО, которые все 8 месяцев жизни «Малых районов Якутии» провели в этой группе, выделены её цветом. Мелкие городские МО показаны точками, пустые места соответствуют 174 территориям с неполной историей.


Какие МО похожи, какие группы они образуют в сети и как группы меняются

Главная модель

Сетевые группы во времени

Временной Leiden на 24 помесечных графах, связь месяцев $\omega = 0,01$. В итоге получается 7 устойчивых групп при основном seed и от 6 до 9 при двух других; 6 групп общие для всех трёх.

На графе следующего месяца сохраняется 93–94% модулярности, у фиксированных центров KMeans4 96%.



Абазинский район и 15 ближайших МО по профилю 2023 года. Профиль учитывает только доли: Песочный (Петербург) похож по долям, но тратит вдвое больше, поэтому аналог проверяю и по типу МО. Группы: ● Города и Москва, ● Ставрополье и Северный Кавказ.

Под ней

Три уровня поселений

Годовой Leiden 2023 года. Правило с ограничением $K \geq 3$ выбрало три группы: районы и округа (1 391), города (376), Москва и Петербург (249).

Без ограничения правило выбирает два уровня. Повторный запуск 2024 года тоже находит две группы: Москва и Петербург сливаются с городами.

С чем сравниваю

KMeans4 по годовому профилю

Сбалансированный, продуктовый, городской сервисный и удалённый типы. Они нужны для сравнения методов и как более детальное описание по тем же признакам.

Также KMeans3, справочник типов МО и ещё 51 разбиение на общих осях. Формальное правило выбора K число 4 не подтверждает.

За два года 1 125 из 2 016 МО хотя бы раз меняют группу. Основу деления задаёт тип поселения, зарплату сверх региона и населения группы почти не объясняют (+0,006–0,009 R^2).

Узел несёт профиль расходов, граф состоит из двух слоёв: сходства профиля и того, чего в признаках нет

Панель СберИндекса: 2 016 МО, 73 региона, 24 месяца. Из 2 190 территорий я убрал 174 с неполной историей.

$$x_{itc} = (\log(E_{itc} / E_{it,total}) - \text{median}_{2023}(c)) / (IQR_{2023}(c) \cdot \sqrt{5})$$

Мне важно, на что тратят, а не сколько. Шкала 2023 года заморожена, 2024 год меряю той же линейкой.

Правило ребра, k = 15	Внутри региона	Жаккар с евклидом	Силуэт K=4
Евклид профиля	17,6%	1	0,362*
Косинус долей	16,5%	0,336	0,333
Пирсон рядов	27,3%	0,059	0,050
Корреляция с лагом	23,9%	0,055	0,043
DTW	24,6%	0,056	0,049
Дороги	71,7%	0,049	н/д

* Вырожденное разбиение с группой из 8 МО. Силуэт посчитан для спектральной кластеризации на графе правила.

Шесть правил видят разное: структурные и динамические делят около 5% рёбер. По профилю группы чёткие, по совместному движению рядов их почти нет.


Помесячная сеть: половина веса у kNN по профилю месяца, половина у дорожной доступности. Дороги не построены из расходов, поэтому группы не сводятся к облакам точек в признаках. Каждый слой делю на сумму его весов, потом складываю.

Годовой каркас: 0,75 · профиль + 0,25 · совместное движение рядов 2023 года (корреляция с лагом до 3 месяцев).

Один динамический слой не годится: его группы устойчивы по seed, но в 2024 году почти не повторяются (ARI 0,24).

Главный ответ: группы во времени

Временной Leiden: три группы живут все 24 месяца, ещё четыре сезонные и региональные



Число МО в каждой из семи устойчивых групп по месяцам и переходы между группами, $\omega = 0,01$, seed 1729. Ленты показывают переходы от 10 МО, серым показаны короткие группы. Группу во времени веду по событиям Greene, Doyle, Cunningham (2010): связь при Жаккаре $\geq 0,3$.


14 групп, 7 устойчивых (живут не меньше 6 месяцев). Три постоянные держат 80,9% наблюдений.

События за 23 перехода: 84 продолжения, 25 ростов, 25 сокращений, 1 слияние, 10 рождений, 10 исчезновений, распадов нет.

Июнь 2023: рождается «Восток и Север» (214 МО). «Продуктовые районы вне лета» пропадают на лето и исчезают совсем в марте 2024 года. В мае 2024 года появляются «Малые районы Якутии».

1 125 МО (55,8%) проходят через две группы и больше; почти половина переходов приходится на обмен между похожими районными группами.

Каждый метод выигрывает на своём графе; на следующем месяце группы Leiden держатся



MQ на смешанном графе месяца (признаки + дороги), по месяцам. Все шесть индексов (SW, CH, S_Dbw, AVI, AVU, MQ) по каждому месяцу и seed лежат в отчёте temporal-quality.

Средние за 24 мес., Leiden с seed 1729	SW	MQ	MQ_next	MQ_mix	Сменили
Leiden $\omega = 0$	0,099	0,476	0,441	0,522	17,7%
Leiden $\omega = 0,01$	0,099	0,473	0,443	0,518	12,3%
KMeans4, центры 2023	0,243	0,520	0,498	0,380	5,8%
KMeans4 заново	0,242	0,596	0,543	0,431	16,1%

Признаковый граф построен из тех же признаков, что KMeans: там выигрывает KMeans. Это круговое сравнение.

На смешанном графе учился Leiden, и там выигрывает Leiden. Это сравнение тоже круговое.

Некруговая проверка MQ_next: у Leiden 93–94% от MQ следующего месяца, у фиксированных центров KMeans4 96%, у KMeans заново 91%. Группы не подогнаны под шум одного месяца, но базовая линия переносится не хуже. ARI между seed при $\omega = 0,01$: 0,86, минимум 0,61.

Правило с $K \geq 3$ выбрало три группы; в 2024 году устойчиво разделение районов и городов

Группа 2023	МО	Население	Зарплата	Продовольствие	Общепит
Районы и округа	1 391	17,9 тыс.	45,9 тыс.	48,1%	1,9%
Города и крупные районы	376	73,1 тыс.	63,4 тыс.	40,4%	4,7%
Москва и Петербург	249	77,7 тыс.	111,3 тыс.	33,2%	7,6%

Медианы по МО. Население и зарплата 2023 года: Росстат, БД ПМО («Если быть точным», СС BY 4.0).

Граф: $0,75 \cdot \text{профиль} + 0,25 \cdot \text{совместное движение рядов}$. Сетка $\alpha \times \gamma$, 20 seed, итогом служит медоид. Правило выбора считает только 2023 год: устойчивость $\geq 0,8$, группа ≥ 20 , парето-фронт по SW и MQ на графе движения 2023 года, сумма рангов (30,75 против 30,25 у следующего варианта по усреднённым рангам summary.json). Ограничение $K \geq 3$ задано в конфиге; ARI между seed в среднем 0,80, минимум 0,33. Первая версия правила считала индексы 2024 года.

0,74 против 0,49

ARI с тем же методом, заново запущенным на 2024 году; справа KMeans3

0,259 против 0,240

SW на профиле 2024 года, справа KMeans3; ось первого отбора

0,258 против 0,223

MQ на графе совместного движения 2024 года, тоже ось первого отбора

Хуже KMeans3: по СН (760 против 938) и MQ на дорожном графе (0,207 против 0,302). SW и MQ 2024 года входили в первую версию правила отбора.

Каркас в основном повторяет иерархию поселений: его ценность в интерпретации, а не в индексах

Разбиение 2023, оценка на 2024	K	SW ↑	CH ↑	S_Dbw ↓	AVI на C ↑	AVU на C ↓	MQ на C ↑	MQ на дорогах ↑	ARI с прогоном 2024 ↑
Сетевая типология (P + C)	3	0,259	760	0,936	0,676	0,667	0,258	0,207	0,74
KMeans4 (базовая линия)	4	0,244	831	0,848	0,471	0,541	0,208	0,276	0,52
KMeans3	3	0,240	938	0,945	0,568	0,667	0,223	0,302	0,49
Спектральная на том же графе	3	0,255	736	1,069	0,652	0,667	0,235	0,184	0,65
Leiden, только профиль	4	0,160	705	0,832	0,515	0,569	0,217	0,304	0,37
Leiden, только движение рядов	4	0,053	325	1,306	0,638	0,532	0,237	0,209	0,24


C обозначает граф совместного движения рядов 2024 года, он не построен из профиля. AVU при K = 3 тождественно равен 2/3, его сравниваю только при равном K. Все варианты сетки и индексы внутри и вне времени лежат в candidates.csv и summary.json.

Спектральная на том же графе почти так же хороша по индексам, но хуже повторяется в 2024 году (0,65).

Один профильный слой неустойчив по seed (ARI 0,57) и не проходит фильтр; один слой движения устойчив, но не повторяется в 2024 году.

56 разбиений на общих осях, с KEFRiN: на невиденных осях каркас не лучше KMeans3, на дорогах уступает справочнику типов МО (средний ранг 5,50 против 2,00 у KEFRiN и 2,50 у KMeans3).

Правило выбора ω подтверждает 0,01, но граница с 0,03 лежит в пределах шума



ω	0	0,01	0,03	0,06	0,1
Средняя MQ	0,476	0,474	0,466	0,462	0,451
Падение от $\omega = 0$	0%	0,4%	2,2%	2,9%	5,3%
ARI соседних месяцев	0,674	0,740	0,832	0,904	0,964
Сменили группу за месяц	17,8%	12,6%	7,4%	3,9%	1,3%

Средние по 24 месяцам и трём seed, MQ на признаковом графе месяца. На слайде 5 стоит 12,3%: там доля сменивших группу посчитана только для seed 1729.

Правило ω : наибольшее ω , при котором средняя MQ падает не больше чем на 2% от $\omega = 0$. Выбрано $\omega = 0,01$.

Граница ω . $\omega = 0,03$ не проходит порог на 0,16 п. п. при разбросе MQ по seed около 1%. На смешанном графе падение при $\omega = 0,1$ всего 1,8%, и то же правило выбрало бы 0,1.

Число групп во времени задаёт модулярность при разрешении $\gamma = 0,7$: 5–8 в месяц. Устойчивой считается группа, которая живёт не меньше 6 месяцев.

Годовой каркас: правило с $K \geq 3$ выбрало три группы, без ограничения выбирает две. Устойчивость 0,804 проходит порог 0,8 впритык, минимум ARI между seed 0,33.

KMeans4 формальное правило выбора K не подтверждает, поэтому в работе он служит только базовой линией.

Без учёта региона группы объясняют зарплату и доступность рынков лучше KMeans4

Группа во времени	МО в мес.	Продукты	Маркет- плейсы	Население	Зарплата, руб.
Сбалансированные районы	792	46,6%	12,6%	19 641	49 745
Продуктовые районы с маркетплейсами	548	46,2%	17,0%	18 346	44 624
Города и Москва	307	32,9%	12,4%	73 451	101 944
Продуктовые районы вне лета	351	46,4%	12,6%	17 957	52 131
Восток и Север	141	44,5%	8,2%	21 100	81 839
Ставрополье и Северный Кавказ	58	36,8%	17,8%	50 476	41 833
Малые районы Якутии	12	45,2%	5,3%	9 062	103 340



Точки: медианы по участникам групп, черты: медиана страны (доли: медианы годовых значений 2023 и 2024 годов; население и зарплата 2023 года: медианы по всем МО).

Правило Миркина: города тратят в общепите на 117% больше средней, Север и Якутия покупают на маркетплейсах на 41% и 61% меньше, Ставрополье на 30% больше.

Внешние показатели, η^2 : зарплата 0,58 против 0,46 у KMeans4 (регион 0,77), доступность рынков 0,60 против 0,41. Население KMeans4 объясняет лучше: 0,45 против 0,17.

Крайний Север: все 72 МО семи северных регионов хотя бы раз попадают в «Восток и Север» или «Малые районы Якутии» и проводят там 48% месяцев. Признака «Север» в модели нет, но география есть в дорожном графе.

Сверх региона и населения к зарплате добавляют: 3 группы 0,006 R^2 , KMeans4 0,008, разница незначима.

Внешние данные в обучение не входят: Росстат и БД ПМО, сопоставление по ОКТМО (население есть у 2 011 МО, зарплата у всех).

Что не получилось и что результат не утверждает

Второй уровень не повторяется. Подтипы внутри районов и городов по 2023 году находятся, но в 2024 году нет (ARI 0,13 и 0). Как ответ я их не использую.

Мало экономики сверх размера. Сверх региона и населения группы добавляют к зарплате 0,006–0,009 R^2 . Отраслевую специализацию не различают.

Дрейф 2023 года у фиксированных центров (сбалансированный тип 930 → 462 МО) вызван общим ростом маркетплейсов: 9,3% → 15,4% за год. Вычитание общего сдвига убирает 70% падения. Временной Leiden к общему тренду нечувствителен по построению.

Круговость. Признаковый граф построен из тех же признаков, что SW и KMeans. Полностью внешние проверки дают только граф движения, дороги, следующий месяц и следующий год. На дорожном графе 2024 года сетевая типология хуже KMeans4 по MQ.

ω на границе шума, на смешанном графе правило дало бы 0,1. Каркас проходит порог устойчивости впритык.

2024 год я видел при разработке, поэтому проверка вне времени разведочная, а не отложенный тест.

МО не взвешены по населению; категории не складываются в полный бюджет; зарплата учитывает только крупные и средние организации.

Одна команда, двенадцать шагов, результаты сверяются с опубликованными

```
bash scripts/reproduce.sh
```

Шаг	Сверка
1–3. Зависимости, архивы, панель и 24 графа	SHA-256 архивов и панели
4. Тесты	все проходят
5. KMeans4	все 2 016 меток
6. Шесть правил рёбер	допуск 1e-4
7. Группы временного Leiden	по сохранённым меткам
8. Сетевая типология	побайтово
9. Индексы по месяцам, выбор ω	побайтово
10. Сравнение 56 разбиений	побайтово
11. Атлас	побайтово
12. Проверка ядра без обучения	статус PASS

Python 3.10–3.12, фиксированные seed, хеши входов в provenance.json каждого отчёта. Временной Leiden скрипт не переобучает, а читает сохранённые метки; команда переобучения есть в REPRODUCE.md, раздел 9.

Атлас: egor2809.github.io/sberindex-clustering

Репозиторий: github.com/Egor2809/sberindex-clustering

Отчёт и методика: REPORT_RU.md, METHODOLOGY_RU.md

Индексы: METRICS.md, temporal-quality, network-core

Архив конфигов и скриптов прошлых этапов: archive